

Attention & Transformer


[\[1706.03762v7\] Attention Is All You Need](#)

2017 NIPS


[\[2010.11929v2\] AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE
RECOGNITION AT SCALE](#)

2021 ICLR

1. Background & Motivation




LSTM



GRU


- 내재적인 계산 병목 현상
- 순차적 특성으로 인한 병렬화 불가
- Gradient Vanishing
- 장거리 의존성 학습의 어려움

2. Model Architecture



- Encoder-Decoder Framework
 - 6 layers in each Encoder and Decoder
 - MHSA(Encoder)
 - Masked MHSA + Encoder-Decoder Attention(Decoder)
 - Feed-forward
 - Residual connections
 - Layer normalization

3. Attention Mechanism



Self-Attention은 “모든 위치 쌍 (i,j) 의 관계를 계산해, i 의 표현을 j 들의 가중합으로 간신히하는” 전역(pairwise) 상호작용 연산이다.


- Base operation = “weighted sum of values”

각 토큰/패치 i 는 다른 모든 토큰/패치 j 를 참조해서 출력을 만든다.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

여기서 softmax가 “ i 가 j 를 얼마나 볼지 정하고, 그 비율로 V 를 섞는다.”

3. Attention Mechanism



- Q/K/V는 “입력의 서로 다른 역할”로 선영 투영된 것

입력 특징 x 에서 Query/Key/Value를 학습된 선형 변환으로 만든다(투영 행렬 W^Q, W^K, W^V).

MultiHead는 이 투영을 여러 세트로 병렬 수행해, 서로 다른 표현 하위공간에서 동시에 관계를 학습한다.

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

한 개의 head의 평균이 주는 표현 손실을 완화하는 설계

4. Positional Encoding

Transformer는 recurrence/convolution이 없기 때문에 sequence에 대한 이해가 없음.
이를 해결하기 위해 모델은 입력 임베딩에 추가되는 위치 인코딩을 통합함.

$$PE_{(pos,2i)} = \sin(pos/10000^{2i/d_{model}})$$

$$PE_{(pos,2i+1)} = \cos(pos/10000^{2i/d_{model}})$$

Transformer의 Positional Encoding은 삼각함수의 덧셈 정리(Trigonometric Addition Theorems)를 이용하여 고정된 오프셋 k 에 대하여 PE_{pos+k} 를 PE_{pos} 의 선형 함수로 표현함.

4. Positional Encoding

$$\begin{pmatrix} PE_{(pos+k, 2i)} \\ PE_{(pos+k, 2i+1)} \end{pmatrix} = \begin{pmatrix} \cos(\omega_i k) & \sin(\omega_i k) \\ -\sin(\omega_i k) & \cos(\omega_i k) \end{pmatrix} \begin{pmatrix} PE_{(pos, 2i)} \\ PE_{(pos, 2i+1)} \end{pmatrix}$$

위치 벡터 $(PE_{(pos, 2i)}, PE_{(pos, 2i+1)})$ 에 특정 각도 $\omega \cdot k$ 만큼 회전시키는 행렬을 곱하면
 k 만큼 떨어진 위치의 벡터를 얻음
이 성질을 통하여 신경망은 절대적인 위치 값 pos 를 직접 알지 못하더라도,
가중치 행렬을 통해 이러한 회전 변환을 학습함으로써
단어들 사이의 상대적인 거리 k 를 파악하고 활용함

5. Applications of Attention

- Encoder-Decoder Attention(Cross-Attention)

이전 decoder layer → Query

Encoder의 출력 → Key/Value

- Self-Attention


Encoder

이전 encoder layer → Query/Key/Value


Decoder

이전 decoder layer → Query/Key/Value

auto-regressive 속성으로 인한 정보의 흐름을 Masking으로 제한




7. Vision Transformer




이미지 패치 처리와 시퀀스 구성을 통하여 Computer Vision Tasks에 Transformer를 적용함

8. Experiments




- 규모 의존적 성능
데이터셋의 크기가 커질 수록 ResNet에 비해 ViT의 성능이 상승한다.

8. Experiments



- 계산 효율성
더 나은 성능을 달성했음에도 ViT는 더 적은 계산 자원을 필요로 한다.




8. Experiments



- 벤치마크 성능

여러 평가 벤치마크에서 JFT-300M으로 사전 훈련된 모델은 이전의 모델들을 능가함




9. Interpretability and Internal Representations



- Left

ViT는 이미지를 Flatten하게 펴서 입력하지만
CNN의 초기 레이어가 선과 색상 같은 저수준 특징을 학습하는 것과 유사하게
첫 번째 필터에서 색상, 엣지 등을 표현하는 기저 함수 형태를 띠고 있음




9. Interpretability and Internal Representations



- Center

가까운 패치일수록, 같은 행, 열에 있을수록 더 유사한 위치 임베딩을 갖는 경향이 있음
모델이 스스로 이미지의 2D 구조를 파악하고 했음을 증명함
모델이 위치 임베딩 간의 유사도를 통해 이미지의 거리 개념을 인코딩하도록 학습됨

9. Interpretability and Internal Representations



- Right

하위 레이어의 어떤 헤드들은 CNN처럼 좁은 영역만 보고, 어떤 헤드들은 이미 전역을 봄
레이어가 깊어질수록 전체를 보는 경향이 커짐

ViT가 CNN의 구조적 제약 없이도, 스스로 이미지의 공간적 구조를 학습하고,
국소적 정보와 전역적 정보를 동시에 처리할 수 있음

10. Impact and Significance

CNN이 고성능 이미지 인식에 필수적이지 않음을 입증함으로써 패러다임 전환을 나타냄

- Architectural Unification
 - 단일 아키텍처가 다양한 데이터 양식에 걸쳐 뛰어날 수 있음을 시사하며,
잠재적으로 multi-modal 시스템의 개발을 단순화함
- Scale as Design Principle
 - 아키텍처 선택 시 훈련 데이터 및 계산 자원의 가용성을 고려해야하며,
일반적인 아키텍처가 더 큰 규모에서 매력적이라는 점을 강조함
- Research Direction
 - Object Detection, Segmentation, Video Understanding에 대한 응용뿐만 아니라
ViT를 위한 자기 지도 학습 연구를 포함하여 Computer Vision 분야에서 새로운 연구방향을 제시함